

École Nationale des Sciences Appliquées de Tétouan

Filière: Big Data & Intelligence Artificielle

Les Méthodes Numériques et Analyse de Donnees

Comparaisons, Applications et Analyses

Réalisé par :

- Abdessamad Ait Brahim

Encadré par :

- Dr. Abdel Louly

Année Académique : 2024-2025

23 mai 2025

Table des matières

1 Comparaison des méthodes directes et itératives pour résoudre $Ax = b$ 3
- 1.1 Méthodes directes . . . 3
  - 1.1.1 Exemples principaux . . . 3
  - 1.1.2 Caractéristiques . . . 3
  - 1.1.3 Avantages et inconvénients . . . 3
- 1.2 Méthodes itératives . . . 3
  - 1.2.1 Exemples principaux . . . 3
  - 1.2.2 Caractéristiques . . . 3
  - 1.2.3 Avantages et inconvénients . . . 4
- 1.3 Tableau comparatif synthétique . . . 4
- 1.4 Analyse approfondie des critères de choix . . . 4

2 Impact de la réduction de dimension via SVD sur l'analyse de données 4
- 2.1 Décomposition en valeurs singulières (SVD) . . . 4
- 2.2 Principe de la réduction de dimension . . . 5
- 2.3 Impacts principaux de la SVD en analyse de données . . . 5
  - 2.3.1 Compression de données . . . 5
  - 2.3.2 Débruitage (Denoising) . . . 5
  - 2.3.3 Visualisation et exploration . . . 5
  - 2.3.4 Optimisation pour l'apprentissage automatique . . . 5
- 2.4 Limites et défis de la SVD . . . 6
  - 2.4.1 Coût computationnel . . . 6
  - 2.4.2 Perte d'interprétabilité . . . 6
  - 2.4.3 Sensibilité aux données manquantes . . . 6
- 2.5 Applications pratiques et cas d'usage . . . 6

3 Analyse en Composantes Principales (ACP) 6
- 3.1 Principe fondamental . . . 6
- 3.2 Avantages détaillés de l'ACP . . . 6
  - 3.2.1 Réduction de dimension optimale . . . 6
  - 3.2.2 Décorrélation des variables . . . 7
  - 3.2.3 Applications en compression et débruitage . . . 7
  - 3.2.4 Capacités de visualisation . . . 7
- 3.3 Limites et précautions d'usage . . . 7
  - 3.3.1 Défis d'interprétation . . . 7
  - 3.3.2 Hypothèse de linéarité restrictive . . . 7

3.3.3 Sensibilité à l'échelle et au prétraitement 7
3.3.4 Robustesse face au bruit 7
3.4 Métriques d'évaluation de l'ACP 8

4 Comparaison et recommandations pratiques **8**
4.1 SVD vs ACP : similitudes et différences 8
4.2 Guide de sélection des méthodes 8
4.2.1 Pour la résolution de systèmes linéaires 8
4.2.2 Pour la réduction de dimension 8

5 Conclusion et perspectives **9**

1 Comparaison des méthodes directes et itératives pour résoudre $Ax = b$

1.1 Méthodes directes

1.1.1 Exemples principaux

— **Élimination de Gauss** : Transformation de la matrice en forme échelonnée

— **Décomposition LU** : Factorisation $A = LU$ où L est triangulaire inférieure et U triangulaire supérieure

— **Décomposition de Cholesky** : Pour matrices symétriques définies positives

1.1.2 Caractéristiques

— Fournissent une solution exacte en théorie (hors erreurs d'arrondi)

— Complexité élevée : $\mathcal{O}(n^3)$ pour une matrice dense

— Sensibles aux erreurs d'arrondi pour des matrices mal conditionnées

— Utilisent beaucoup de mémoire, car elles modifient directement la matrice

1.1.3 Avantages et inconvénients

Avantages	Inconvénients
Rapidité sur petites matrices	Peu adaptées aux très grandes matrices
Résultats stables pour matrices bien conditionnées	Consomment beaucoup de mémoire
Solution exacte (théoriquement)	Inefficaces pour matrices creuses

1.2 Méthodes itératives

1.2.1 Exemples principaux

— **Méthode du gradient conjugué (CG)** : Optimale pour matrices symétriques définies positives

— **Méthode de Jacobi** : Itération simple avec décomposition $A = D + R$

— **Méthode de Gauss-Seidel** : Utilisation immédiate des valeurs mises à jour

1.2.2 Caractéristiques

— Donnent une solution approchée après un nombre d'itérations

— Convergence dépend de la condition de la matrice

— Complexité par itération : $\mathcal{O}(n^2)$, voire mieux pour matrices creuses

1.2.3 Avantages et inconvénients

Avantages	Inconvénients
Peu de mémoire requise	Risque de non-convergence
Efficaces pour grandes matrices creuses	Nécessitent de bons préconditionneurs
Faciles à paralléliser	Moins précises si mal configurées
Exploitent la structure des matrices	Nombre d'itérations imprévisible

1.3 Tableau comparatif synthétique

Critère	Méthode directe	Méthode itérative
Temps (petite taille)	Rapide	Plus lent au début
Temps (grande taille)	Trop coûteux	Très efficace
Précision	Très bonne	Approximative
Mémoire	Très coûteuse	Optimisée
Robustesse	Moyenne	Dépend convergence

1.4 Analyse approfondie des critères de choix

Le choix entre méthodes directes et itératives dépend de plusieurs facteurs cruciaux :

Taille du système : Pour $n < 1000$, les méthodes directes sont généralement préférables. Au-delà, notamment pour $n > 10^4$, les méthodes itératives deviennent incontournables.

Structure de la matrice :

- Matrices denses : méthodes directes si la taille le permet
- Matrices creuses : méthodes itératives quasi-obligatoires
- Matrices bien conditionnées : choix libre selon la taille
- Matrices mal conditionnées : préconditionnement nécessaire pour les méthodes itératives

Ressources disponibles : La mémoire disponible est souvent le facteur limitant. Les méthodes directes nécessitent $\mathcal{O}(n^2)$ d'espace mémoire, tandis que les méthodes itératives n'en requièrent que $\mathcal{O}(n)$.

2 Impact de la réduction de dimension via SVD sur l'analyse de données

2.1 Décomposition en valeurs singulières (SVD)

La décomposition en valeurs singulières d'une matrice $A \in R^{m \times n}$ s'écrit :

$$A = U \Sigma V^T$$

où :

$$U \in R^{m \times m} : \text{vecteurs propres à gauche (orthogonaux)} \quad (1)$$
$$\Sigma \in R^{m \times n} : \text{valeurs singulières (diagonale, décroissantes)} \quad (2)$$
$$V \in R^{n \times n} : \text{vecteurs propres à droite (orthogonaux)} \quad (3)$$

2.2 Principe de la réduction de dimension

On peut approximer A par $A_k = U_k \Sigma_k V_k^T$ en conservant seulement les k plus grandes valeurs singulières.

Cette approximation de rang faible minimise l'erreur de Frobenius :

$$\|A - A_k\|_F = \sqrt{\sum_{i=k+1}^{\min(m,n)} \sigma_i^2}$$

2.3 Impacts principaux de la SVD en analyse de données

2.3.1 Compression de données

La SVD permet une compression efficace en éliminant les dimensions redondantes :

— **Taux de compression** : $(m + n)k$ paramètres au lieu de mn

— **Ratio d'information préservée** : $\frac{\sum_{i=1}^{k} \sigma_i^2}{\sum_{i=1}^{\min(m,n)} \sigma_i^2}$

2.3.2 Débruitage (Denoising)

Les petites valeurs singulières correspondent souvent au bruit :

— Filtrage naturel du bruit haute fréquence

— Amélioration du rapport signal/bruit

— Stabilisation des calculs ultérieurs

2.3.3 Visualisation et exploration

— Projection dans des espaces 2D/3D interprétables

— Préservation de la structure géométrique des données

— Identification de patterns cachés

2.3.4 Optimisation pour l'apprentissage automatique

— Réduction de la complexité des modèles

— Prévention du surapprentissage (overfitting)

— Accélération des algorithmes d'apprentissage

— Amélioration de la généralisation

2.4 Limites et défis de la SVD

2.4.1 Coût computationnel

— Complexité $\mathcal{O}(\min(mn^2, m^2n))$ pour la SVD complète
— Méthodes approximatives nécessaires pour très grandes matrices
— Algorithmes randomisés pour l'approximation rapide

2.4.2 Perte d'interprétabilité

— Les nouveaux axes n'ont plus de signification physique directe
— Combinaisons linéaires complexes des variables originales
— Difficulté d'explication des résultats aux experts métier

2.4.3 Sensibilité aux données manquantes

— SVD classique exige des matrices complètes
— Nécessité d'imputation préalable
— Alternatives : SVD tronquée, méthodes itératives

2.5 Applications pratiques et cas d'usage

Domaine	Application	Bénéfice principal
Vision par ordinateur	Reconnaissance faciale	Réduction dimensionnelle
Traitement du langage	Analyse sémantique	Capture des relations
Recommandation	Filtrage collaboratif	Factorisation de matrices
Finance	Analyse de risque	Identification de facteurs
Bioinformatique	Analyse d'expression	Clustering et classification

3 Analyse en Composantes Principales (ACP)

3.1 Principe fondamental

L'ACP est une technique de réduction de dimension basée sur la diagonalisation de la matrice de covariance. Elle transforme les variables d'origine en un nouveau système d'axes (composantes principales) orthogonaux qui maximisent la variance expliquée.

Mathématiquement, si X est la matrice des données centrées, l'ACP consiste à :

1. Calculer la matrice de covariance : $C = \frac{1}{n-1} X^T X$
2. Diagonaliser C : $C = PDP^T$ où D contient les valeurs propres
3. Projeter : $Y = XP$ (nouvelles coordonnées)

3.2 Avantages détaillés de l'ACP

3.2.1 Réduction de dimension optimale

— Préserve la variance maximale dans les premières composantes
— Minimise la perte d'information selon le critère des moindres carrés
— Permet de choisir le nombre de dimensions selon un seuil de variance expliquée

3.2.2 Décorrélation des variables

— Les composantes principales sont orthogonales par construction
— Élimination des redondances entre variables
— Facilitation des analyses statistiques ultérieures

3.2.3 Applications en compression et débruitage

— Compression avec perte contrôlée
— Filtrage du bruit dans les dernières composantes
— Amélioration de la qualité des données d'entrée pour ML

3.2.4 Capacités de visualisation

— Projection naturelle en 2D/3D
— Préservation des distances relatives
— Révélation de structures cachées dans les données

3.3 Limites et précautions d'usage

3.3.1 Défis d'interprétation

— Les composantes sont des combinaisons linéaires complexes
— Perte du sens physique des variables originales
— Nécessité d'expertise pour interpréter les résultats

3.3.2 Hypothèse de linéarité restrictive

— Incapacité à capturer des relations non linéaires
— Alternatives : Kernel PCA, t-SNE, UMAP pour la non-linéarité
— Performance dégradée sur des données avec structures courbes

3.3.3 Sensibilité à l'échelle et au prétraitement

— Nécessité absolue de centrer les données
— Importance de la standardisation pour variables d'échelles différentes
— Impact critique des outliers sur les résultats

3.3.4 Robustesse face au bruit

— Sensibilité aux valeurs aberrantes
— Propagation du bruit dans toutes les composantes
— Nécessité de prétraitement robuste (détection d'outliers)

3.4 Métriques d'évaluation de l'ACP

Variance expliquée :

$$\text{Variance expliquée par PC}_i = \frac{\lambda_i}{\sum_{j=1}^{p} \lambda_j}$$

Variance cumulée :

$$\text{Variance cumulée jusqu'à PC}_k = \frac{\sum_{i=1}^{k} \lambda_i}{\sum_{j=1}^{p} \lambda_j}$$

Critères de sélection du nombre de composantes :

- Règle de Kaiser : conserver les valeurs propres > 1
- Critère du coude : recherche de la rupture dans le graphique des valeurs propres
- Seuil de variance : conserver 80-95% de la variance totale

4 Comparaison et recommandations pratiques

4.1 SVD vs ACP : similitudes et différences

Aspect	SVD	ACP
Base mathématique	Décomposition matricielle	Diagonalisation covariance
Centrage requis	Non nécessairement	Obligatoire
Matrices rectangulaires	Oui	Non (carrée via covariance)
Interprétation	Plus générale	Plus statistique
Coût computationnel	Plus élevé	Plus efficace

4.2 Guide de sélection des méthodes

4.2.1 Pour la résolution de systèmes linéaires

- $n < 1000$ et matrice dense : méthodes directes (LU, Cholesky)
- $n > 1000$ ou matrice creuse : méthodes itératives (CG, GMRES)
- Matrices mal conditionnées : préconditionnement + méthodes itératives
- Mémoire limitée : toujours méthodes itératives

4.2.2 Pour la réduction de dimension

- Données centrées, relations linéaires : ACP
- Matrices rectangulaires, compression : SVD
- Relations non linéaires : Kernel PCA, t-SNE, UMAP
- Très grandes dimensions : SVD randomisée ou ACP incrémentale

5 Conclusion et perspectives

Les méthodes numériques présentées constituent les fondements de l'analyse de données moderne. Le choix approprié entre méthodes directes et itératives, ainsi que l'utilisation judicieuse de la réduction de dimension via SVD ou ACP, dépendent crucialement :

1. De la taille et structure des données
2. Des ressources computationnelles disponibles
3. Du niveau de précision requis
4. Des contraintes d'interprétabilité

L'évolution vers des données de plus en plus volumineuses (Big Data) favorise naturellement les méthodes itératives et les techniques de réduction de dimension. Les développements futurs s'orientent vers :

— Algorithmes adaptatifs et auto-optimisants
— Méthodes hybrides combinant plusieurs approches
— Intégration de l'intelligence artificielle dans le choix des méthodes
— Optimisations pour architectures parallèles et distribuées

La maîtrise de ces concepts reste essentielle pour tout praticien de l'analyse de données et du calcul scientifique.